UBO · EVALUACIÓN 03 · MACHINE LEARNING

Detección automática de maquinaria de construcción

YOLO26n · Transfer learning · Fine tuning
Evidencia experimental reproducible, evaluación y análisis crítico

86,59 %	71,66 %	90,13 %
mAP50 · Test	mAP50-95 · Test	Precision · Test

Autores · Mathis Marsault · Julien Martinat · Louis Maillet

Docente · Dr. Eliecer Peña Ancavil

Universidad · Universidad Bernardo O'Higgins, Santiago

Entrega · 7 de noviembre de 2026

Grupo y módulo · Completar antes de la entrega en aula virtual

1. Problema y dataset

Propósito y usuarios potenciales

En una obra es habitual encontrar distintas máquinas pesadas en un mismo campo visual. Este proyecto estudia si un detector de objetos basado en YOLO26n puede **localizar y clasificar** automáticamente tres tipos de maquinaria mediante cajas delimitadoras (*bounding boxes*): `EXCAVATORS` (excavadoras), `dump truck` (camiones de volteo) y `wheel loader` (cargadoras frontales). Un resultado de este tipo podría ayudar, de manera exploratoria, a documentar imágenes de obras, clasificar contenido audiovisual y apoyar inventarios visuales. No se plantea un sistema de seguridad ni se garantiza un funcionamiento fiable en situaciones críticas.

Fuente, licencia y clases

Se utilizó **Excavators**, de Mohamed Sabek en Roboflow Universe, **versión 2**, exportada en formato **YOLOv8** y publicada con licencia **CC BY 4.0**. Sus imágenes originales se habían redimensionado a 416 × 416 píxeles. Elegimos exactamente las tres categorías ya presentes en el `data.yaml`; por tanto, no fue necesario etiquetar manualmente ni crear clases artificiales.

Fuente verificable: https://universe.roboflow.com/mohamed-sabek-6zmr6/excavators-cwlh0/dataset/2

Tabla 1. Tamaño del conjunto de trabajo después de la auditoría y antes de entrenar.

Conjunto	Imágenes	Excavadoras	Camiones	Cargadoras	Cajas totales
Train	2 406	1 477	1 067	973	3 517
Validation	144	35	120	55	210
Test	82	17	80	30	127
Total	**2 632**	**1 529**	**1 267**	**1 058**	**3 854**

La disponibilidad de fotografías y vídeos reales de maquinaria permite demostrar detecciones fuera del dataset. Para la posterior Evaluación 04 se reservaron dos clips externos de al menos diez segundos, con la procedencia indicada en las referencias.

2. Preparación de los datos

Anotaciones y configuración

Cada imagen se asocia a un archivo `.txt` con una línea por caja: `clase x_centro y_centro ancho alto`. Las cuatro coordenadas son proporciones de la anchura y altura de la imagen. Por ejemplo, una anotación real de Train fue `0 0.5661057692 0.4507211538 0.7572115385 0.9014423077`, que significa: clase 0 (*EXCAVATORS*), centro horizontal en el 56,61 % de la anchura, centro vertical en el 45,07 % de la altura, caja de ancho 75,72 % y alto 90,14 % del tamaño de imagen.

La estructura final contiene `train/images`, `train/labels`, `valid/images`, `valid/labels`, `test/images` y `test/labels`. El archivo `data.yaml` identifica las rutas y los nombres de clase; el código transforma `valid` en `val` sin mezclar las particiones. Se revisaron etiquetas mal formadas y límites de cajas, con resultados válidos. Algunos ejemplos sin caja se mantienen como fondos negativos.

Control de fuga entre particiones

La auditoría detectó un problema no evidente: fotogramas de **las mismas secuencias de vídeo** aparecían inicialmente en Train, Validation y Test, aunque sus archivos no eran duplicados exactos por SHA256. Para evitar que Test contuviera escenas casi memorizadas del entrenamiento, se trasladaron **161 fotogramas** al conjunto Train, agrupando los clips identificables por sus nombres. Después, un filtro de similitud visual (dHash de 64 bits, distancia ≤ 6; correlación de grises 64 × 64 ≥ 0,985) excluyó **24 fotografías casi idénticas** de Validation/Test.

La exportación original tenía 2 656 imágenes y 3 881 cajas; el conjunto de trabajo quedó en 2 632 imágenes y 3 854 cajas. Las reglas, parámetros, imágenes excluidas y recuentos están registrados en `LIMPIEZA_DATOS.json` y documentados en `docs/AUDITORIA_DATASET.md`. La limpieza se aplicó **antes de entrenar** y no respondió a resultados de Test.

Límite: los umbrales automáticos y los nombres de los clips no garantizan independencia absoluta de escenas similares. Las 82 imágenes de Test y, especialmente, sus **17 cajas de excavadoras** hacen que los resultados por clase deban interpretarse con cautela.

3. Entrenamiento

El trabajo se ejecutó en **Google Colab gratuito** con GPU **NVIDIA Tesla T4 (14 913 MiB)** y Ultralytics **8.4.192**. Se fijó una semilla 42, `imgsz=416`, lote de 16 imágenes y utilización del 100 % de Train. El entrenamiento consta de dos etapas obligatorias.

Tabla 2. Configuraciones efectivamente aplicadas y tiempo.

Parámetro	Transfer learning	Fine tuning
Modelo de partida	`yolo26n.pt` preentrenado	`best.pt` propio del transfer
Épocas	8	5
Resolución	416 × 416	416 × 416
Fracción Train	1,0	1,0
Lote (batch)	16	16
Capas congeladas	`freeze=10`	`freeze=0`
Optimizador real	AdamW, elegido por `auto`	AdamW
Learning rate inicial efectivo	**0,001429**	**0,0001**
GPU	Tesla T4	Tesla T4
Tiempo medido	**213,76 s**	**135,60 s**
Mejor época	8	3

Importante: en la primera etapa se pasó `lr0=0.01` como argumento, pero Ultralytics avisó que `optimizer=auto` lo **ignoró** y fijó en realidad AdamW con **lr=0,001429**. El valor correcto que se presenta es el aplicado por el entrenamiento, no el solicitado en el código.

Evolución de las pérdidas y del mAP

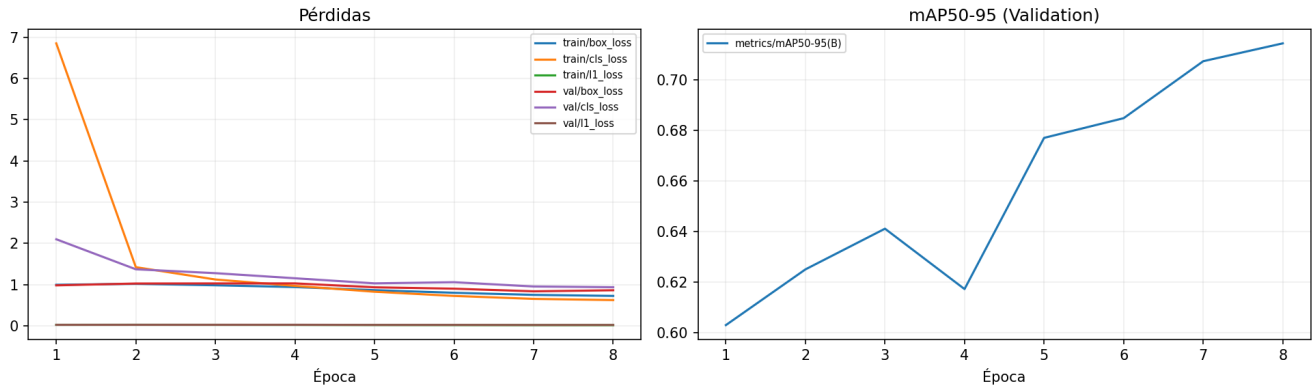


Figura 1. Transfer learning (8 épocas). Las pérdidas de entrenamiento se reducen y el mAP50-95 de Validation progresa, con mejor resultado al final de esta etapa.

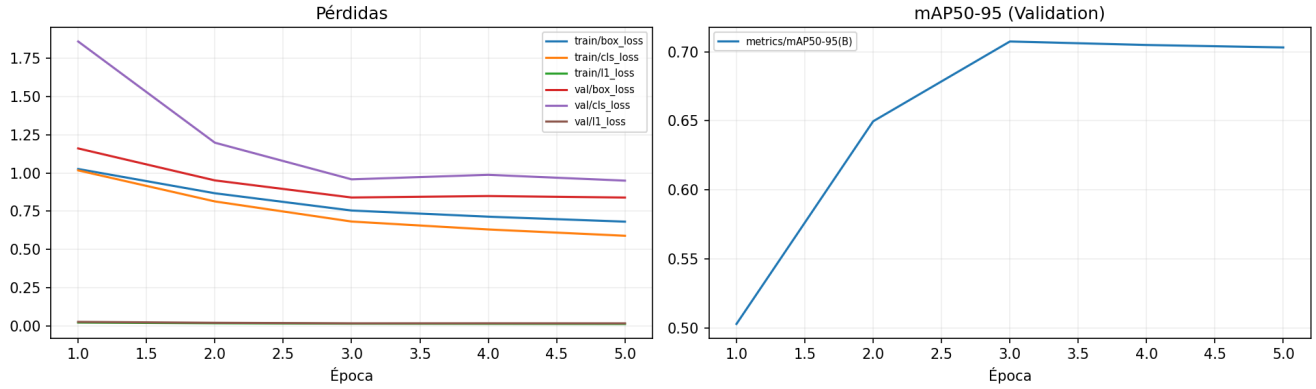


Figura 2. Fine tuning (5 épocas). La mejor métrica de Validation aparece en la época 3 y se estabiliza o disminuye levemente después; más épocas no implicaron automáticamente mejor generalización.

4. Resultados en Validation y elección del modelo

Se calcularon Precision, Recall, mAP50 y mAP50-95 con el **mismo conjunto Validation** y resolución de 416 píxeles. La selección estaba fijada **antes de mirar Test**: mayor mAP50-95, con desempate por mAP50 y posteriormente a favor del transfer learning.

Tabla 3. Evaluación de ambos mejores pesos en Validation (144 imágenes, 210 cajas).

Modelo	Precision	Recall	mAP50	mAP50-95
Transfer learning	**0,8863**	0,8006	0,8708	**0,7129**
Fine tuning	0,8319	**0,8350**	**0,8749**	0,7076

Se eligió **transfer learning**, con una ventaja pequeña de **0,00535** en mAP50-95 (≈0,54 puntos porcentuales). El fine tuning detectó una proporción mayor de objetos (recall +0,0344) y obtuvo mAP50 ligeramente superior, pero perdió precisión y no mejoró la métrica principal de selección. Por ello no se argumenta que el fine tuning sea inútil: ambos modelos presentan un compromiso diferente.

Para el seleccionado se contaron **165 verdaderos positivos (TP)**, **35 falsas detecciones (FP)** y **45 objetos perdidos (FN)** en Validation, utilizando confianza mínima 0,25, IoU mínimo 0,50 y emparejamiento por la misma clase. Una falsa detección puede crear un equipo inexistente en un

inventario visual; un objeto perdido puede hacer que no se contabilice maquinaria visible. Estos conteos ilustrativos **no son idénticos** al cálculo de Precision/Recall de la evaluación Ultralytics, que considera barridos de umbrales.

5. Evaluación en Test y análisis de errores

La evaluación final se realizó **una sola vez**, después de registrar la selección, con `modelo_elegido.pt` y `imgsz=416`, sobre **82 imágenes y 127 cajas**. No se utilizó Test para elegir el modelo, ajustar hiperparámetros ni seguir entrenando.

Tabla 4. Métricas globales del conjunto Test.

Precision	Recall	mAP50	mAP50-95
0,9013	**0,7705**	**0,8659**	**0,7166**

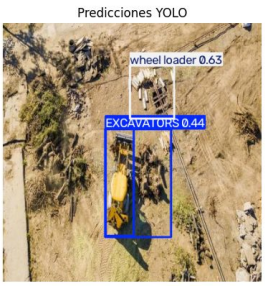
Tabla 5. Desglose por categoría en Test.

Clase	Cajas	Precision	Recall	mAP50	mAP50-95
EXCAVATORS	17	0,848	0,765	0,864	0,699
dump truck	80	0,950	0,713	0,839	0,685
wheel loader	30	0,906	0,833	0,894	0,766

El mAP50-95 pasó de 0,7129 en Validation a **0,7166 en Test**, mientras que el recall pasó de 0,8006 a **0,7705**. No se observa una caída general de mAP50-95, pero eso **no demuestra** capacidad industrial robusta: el conjunto Test es pequeño y la categoría de excavadoras tiene muy pocas instancias.

Evidencias cualitativas y errores representativos





Vista cenital: cargadora y etiqueta adicional de excavadora.





Cargadora: detección espuria de camión de volteo.





Ejemplo representativo de detección correcta de camión.

Figura 3. Comparación entre las cajas reales (columna izquierda) y las detecciones del modelo (derecha) sobre seis fotografías de Test. Las predicciones muestran aciertos claros, pero también cajas espurias o confusiones entre clases.

Error 1 — Confusión de clase (Test). En una vista cenital de `wheel loader`, aparece una predicción adicional `EXCAVATORS` con confianza **0,44** sobre la maquinaria. La perspectiva aérea y la geometría parcialmente visible podrían explicar esta ambigüedad. La superposición no se interpreta como un segundo equipo real.

Error 2 — Falsa detección (Test). En otra `wheel loader`, parte de la máquina genera una caja `dump truck` con confianza **0,26**. El resultado está próximo al umbral de 0,25, por lo que evidencia sensibilidad a rasgos visuales compartidos y a la decisión de confianza.

Error 3 — Objeto perdido (Test: evidencia cuantitativa, no visual). El **Recall de Test = 0,7705**, inferior a 1, demuestra que el modelo no recuperó todos los objetos anotados. Estos fallos de omisión podrían afectar a un inventario visual. No se recuperó una pareja concreta de caja real y predicción de Test para ilustrar un FN individual; por rigor, **no se atribuye este fallo a una imagen específica**. Como evidencia independiente, el conteo a umbral fijo de **Validation** fue de **45 FN** (confianza 0,25; IoU 0,50), pero no se confunden ambos conjuntos. La falta de una captura inequívoca de FN en Test continúa siendo una limitación cualitativa del material disponible.

6. Uso con imágenes y vídeo externos

Se probaron **dos fotografías externas** al dataset, obtenidas de Pexels, con el `modelo_elegido.pt` (416 px, confianza mínima 0,25). La primera produjo una detección `wheel loader`; la segunda produjo `EXCAVATORS` y `dump truck`. En las imágenes anotadas recibidas se observaron respectivamente confianzas aproximadas de **0,42** para la cargadora y de **0,68 / 0,28** para las otras dos categorías. La detección de confianza 0,28 es débil y podría ser espuria; no se presenta como un acierto seguro. Las imágenes con las cajas predichas se generaron en `results/external_images` del respaldo ZIP del equipo; **el notebook entregado solo incorpora sus registros de inferencia, no estas capturas**, por lo que no se incluyen supuestas imágenes anotadas que no se hayan recuperado. La primera fotografía presenta una detección con confianza moderada y la segunda muestra una detección de baja confianza que requiere comprobación humana.

Tabla 6. Material externo utilizado.

Recurso	Procedencia	Resultado verificado
Fotografía 1	Pexels, Rohan Batra, imagen 40537857	1 `wheel loader`
Fotografía 2	Pexels, celal keser, imagen 36506004	1 `EXCAVATORS` y 1 `dump truck`
Vídeo 1	Archivo externo `16517436_3840_2160_30fps.mp4`	245 fotogramas anotados
Vídeo 2	Archivo externo `16499298_3840_2160_30fps.mp4`	199 fotogramas anotados

Ambos vídeos externos se transformaron de 4K a **720p / 10 fps** para limitar el uso de RAM de Colab, sin modificar el modelo. La inferencia se realizó con `stream=True` para no almacenar todas las predicciones en memoria. Se obtuvieron clips procesados de **24,5 y 19,9 segundos** aproximadamente. Los vídeos se introdujeron como material externo al entrenamiento; su independencia respecto del dataset se declara según el protocolo utilizado, sin equivaler a una comprobación exhaustiva de procedencia. Los dos clips anotados se guardaron en `results/video_1_streaming` y `results/video_2_streaming` en el archivo de evidencias, fuera del repositorio por su tamaño.

Estas pruebas muestran que el detector funciona en fuentes externas al dataset, pero las dos imágenes y dos vídeos **no constituyen una nueva prueba estadística independiente**. La iluminación, la distancia, el tamaño aparente de las máquinas y el punto de vista pueden modificar tanto las confianzas como la localización de las cajas. En particular, una predicción con confianza baja exige verificación humana.

7. Conclusiones y límites

El equipo construyó y entrenó un detector YOLO26n propio para tres tipos de maquinaria, comparó de forma controlada dos estrategias y seleccionó un modelo **sin consultar Test**. El modelo elegido alcanzó **mAP50=0,8659** y **mAP50-95=0,7166** en el conjunto Test depurado, con una **Precision=0,9013** y un **Recall=0,7705**. Este último valor también confirma que el detector pierde algunos objetos; los ejemplos visuales publicados no identifican todavía un caso concreto de FN en Test. La demostración en fotografías y vídeos externos confirma que puede producir cajas sobre material nuevo, aunque también aparecen falsas detecciones y clasificaciones confusas.

El fine tuning mejoró recall y mAP50 en Validation, pero no mejoró el mAP50-95 usado como criterio de selección. El resultado ilustra la importancia de **comparar modelos con una regla declarada**, y no elegir automáticamente la etapa más larga.

Las limitaciones más importantes son el tamaño y el reparto de Test, la fuerte desproporción de cajas por categoría, la similitud visual entre máquinas, la dependencia del punto de vista y la detección no exhaustiva de escenas duplicadas. Ninguna cifra permite afirmar seguridad operativa, recuentos infalibles ni precisión estable fuera de las condiciones evaluadas.

Con más tiempo de GPU se podría ampliar el dataset con obras, cámaras y condiciones meteorológicas variadas; auditar manualmente las etiquetas; incorporar escenas agrupadas por fuente; realizar entrenamientos de más épocas y varias semillas con selección exclusiva en Validation, y estudiar tamaños de imagen alternativos antes de una **nueva** evaluación final en un Test independiente. Son **mejoras propuestas**, no realizadas.

Referencias

1. Universidad Bernardo O’Higgins. *Evaluación 03 — Proyecto YOLO: un detector de objetos entrenado por ustedes* (consigna de la asignatura, 2026) y *Formato de informe Evaluación 03*.
2. Mohamed Sabek. *Excavators — Computer Vision Model*, dataset v2, Roboflow Universe. CC BY 4.0. https://universe.roboflow.com/mohamed-sabek-6zmr6/excavators-cwlh0/dataset/2
3. Ultralytics. *YOLO26 Documentation*. https://docs.ultralytics.com/models/yolo26/
4. Pexels. Rohan Batra. Imagen 40537857. https://www.pexels.com/photo/heavy-machinery-at-indian-construction-site-40537857/
5. Pexels. celal keser. Imagen 36506004. https://www.pexels.com/photo/dump-truck-and-excavator-at-construction-site-36506004/
6. Material audiovisual externo empleado en el notebook: `16517436_3840_2160_30fps.mp4` (24,5 s) y `16499298_3840_2160_30fps.mp4` (19,9 s). Los nombres identifican los archivos efectivamente procesados, pero **no permiten verificar autoría, página de origen o licencia**; sus referencias bibliográficas completas no están acreditadas en los materiales del equipo.

Código, anotaciones de control, CSV de entrenamiento, gráficos de pérdidas, métricas, pesos y vídeos anotados documentados en el repositorio de la asignatura y en el archivo de resultados del equipo. Los modelos `.pt` se entregan por separado.